

BÁO CÁO DỰ ÁN: HYBRID BOOKS RECOMMENDATION SYSTEM

Nhóm thực hiện: Nhóm 5 Dữ liệu sử dụng: Book-Crossing Dataset

I. TỔNG QUAN DỰ ÁN (OVERVIEW)

1. Mục tiêu

Xây dựng một hệ thống gợi ý sách thông minh có khả năng giải quyết các vấn đề kinh điển trong hệ thống gợi ý (Recommender System) như: dữ liệu thưa (sparsity) và vấn đề khởi động lạnh (cold-start problem) cho người dùng mới.

2. Giải pháp đề xuất

Sử dụng phương pháp **Lai ghép (Hybrid Approach)** kết hợp 3 mô hình con để phục vụ 3 nhóm đối tượng người dùng khác nhau:

- Collaborative Filtering (ALS):** Dành cho người dùng tương tác nhiều (Core Users).
- Content-Based Filtering:** Dành cho người dùng ít tương tác (Lukewarm Users).
- Popularity-Based:** Dành cho người dùng mới hoàn toàn (Cold Users).

II. PHÂN TÍCH DỮ LIỆU (DATA UNDERSTANDING)

1. Bộ dữ liệu

- Nguồn:** Book-Crossing Dataset (thu thập năm 2004).
- Thành phần:**
 - Users:** 278,858 người dùng (ẩn danh).
 - Books:** 271,360 đầu sách (ISBN, Tựa đề, Tác giả, NXB).
 - Ratings:** 1,149,780 lượt đánh giá (thang điểm 1-10 hoặc 0).

2. Vấn đề của dữ liệu (Insights)

- Độ thưa (Sparsity):** ~99.99%. Hầu hết người dùng đánh giá rất ít sách, và hầu hết sách nhận được rất ít đánh giá.
- Phân phối:** Dạng "đuôi dài" (Long-tail). Chỉ một số ít sách nổi tiếng có nhiều tương tác, còn lại rất ít.

III. PHƯƠNG PHÁP & MÔ HÌNH HÓA (METHODOLOGY)

Hệ thống được chia thành 3 tầng xử lý tùy thuộc vào lịch sử dữ liệu của người dùng:

Mô hình A: Lọc cộng tác (Collaborative Filtering) - Kỹ thuật ALS

- Đối tượng:** "Core Users" (Người dùng đã đánh giá > 50 sách).
- Thuật toán:** Alternating Least Squares (ALS) từ thư viện `implicit`.
- Nguyên lý:** Phân rã ma trận tương tác (Matrix Factorization) để tìm ra các đặc trưng ẩn (latent factors) của người dùng và sách. Từ đó dự đoán sở thích dựa trên hành vi của những người dùng giống nhau.
- Đầu vào:** Ma trận thưa (Sparse Matrix) giữa User và Book.

Mô hình B: Lọc theo nội dung (Content-Based Filtering)

- Đối tượng:** "Lukewarm Users" (Người dùng có ít đánh giá, < 50 sách).
- Thuật toán:** TF-IDF Vectorizer + Cosine Similarity.
- Nguyên lý:** Gợi ý các cuốn sách có nội dung tương tự với cuốn sách cuối cùng mà người dùng đã đọc.
- Đặc trưng sử dụng:** Tên tác giả (`Book-Author`) và Nhà xuất bản (`Publisher`).

Mô hình C: Phổ biến (Popularity-Based) - Fallback

- Đối tượng:** "Cold Users" (Người dùng mới 100%, chưa có lịch sử).
- Nguyên lý:** Đếm số lượng rating của từng cuốn sách và gợi ý Top các cuốn sách được đọc nhiều nhất.

IV. QUY TRÌNH THỰC HIỆN & KỸ THUẬT (IMPLEMENTATION)

- Chuẩn bị môi trường:**
 - Cài đặt các thư viện tương thích: `numpy<2.0`, `scipy==1.12.0`, `implicit==0.7.2` (để tránh lỗi xung đột version).
- Tiền xử lý dữ liệu (Data Prep):**
 - Lọc bỏ các rating = 0 (giữ lại tương tác tích cực).
 - Loại bỏ các sách trùng lặp.
 - Đối với ALS:** Lọc nghiêm ngặt, chỉ giữ lại User và Book có ít nhất 50 tương tác để đảm bảo mô hình học tốt.
 - Đối với Content-Based:** Tạo cột đặc trưng văn bản kết hợp từ Tác giả + NXB.
- Huấn luyện (Training):**

- **ALS:** Huấn luyện trên tập dữ liệu "Lõi" (Core Data). Tham số: `factors=40`, `iterations=20`.
 - **Content-Based:** Vector hóa dữ liệu bằng TF-IDF.
4. **Xây dựng bộ điều phối (Hybrid Logic):**
- Viết hàm `get_hybrid_recommendations(user_id)` để tự động chuyển hướng sang mô hình phù hợp.
-

V. ĐÁNH GIÁ HIỆU NĂNG (EVALUATION)

1. ĐÁNH GIÁ MÔ HÌNH A: ALS (Collaborative Filtering)

Mô hình này học từ hành vi người dùng. Để đánh giá, hệ thống thực hiện:

- **Chia dữ liệu (Split):** Lấy tập "User Lõi" (những người tương tác nhiều), chia 80% dữ liệu để huấn luyện (Train) và giấu đi 20% dữ liệu để kiểm tra (Test).
- **Nhiệm vụ:** Mô hình phải đoán xem 20% những cuốn sách bị giấu đi đó là sách gì.

Các chỉ số đo lường (Metrics) và Kết quả thực tế:

Dưới đây là ý nghĩa của các con số xuất hiện trong Notebook:

1. Precision@10 (Độ chính xác trong top 10)

- **Kết quả:** `~0.1281` (hay 12.81%)
- **Giải thích:** Khi hệ thống gợi ý 10 cuốn sách cho một người dùng, trung bình có khoảng **1 đến 2 cuốn** (1.28 cuốn) là sách người đó thực sự đã đọc/thích trong tập Test.
- **Đánh giá:** Với bài toán Recommendation trên tập dữ liệu cực thưa (sparsity 99.99%) và kho sách khổng lồ (hàng trăm nghìn cuốn), con số 12.8% là **chấp nhận được và có giá trị thực tiễn**. Nó tốt hơn nhiều so với việc chọn ngẫu nhiên (tỷ lệ trúng gần như bằng 0).

2. Recall@10 / Hit Rate (Độ bao phủ)

- **Kết quả:** `~0.1331` (hay 13.31%)
- **Giải thích:** Trong tổng số những cuốn sách người dùng thích (nằm trong tập Test), hệ thống tìm lại được bao nhiêu? Ở đây là 13.31%.
- **Đánh giá:** Chỉ số này cho thấy mô hình không thể tìm lại hết mọi sở thích của người dùng (điều này rất khó), nhưng nó nắm bắt được một phần đáng kể xu hướng đọc sách của họ.

3. MAP@10 (Mean Average Precision - Độ chính xác trung bình)

- **Kết quả:** `~0.0675`
- **Giải thích:** Chỉ số này khắt khe hơn Precision. Nó quan tâm đến **thứ hạng**. Nếu sách đúng nằm ở vị trí số 1, điểm sẽ cao hơn nằm ở vị trí số 10.

- **Đánh giá:** Điểm thấp hơn Precision cho thấy mặc dù mô hình đoán đúng sách, nhưng những sách đúng đó thường nằm ở các vị trí thấp hơn trong danh sách gợi ý (ví dụ: vị trí 7, 8, 9 thay vì 1, 2, 3).

4. AUC (Area Under the Curve)

- **Kết quả:** ~0.5558
- **Giải thích:** Xác suất để một cuốn sách người dùng thích được xếp hạng cao hơn một cuốn sách ngẫu nhiên. Mức 0.5 là đoán mò ngẫu nhiên.
- **Đánh giá:** Kết quả 0.55 cho thấy mô hình có học được tri thức (tốt hơn ngẫu nhiên), nhưng bị ảnh hưởng nặng nề bởi nhiễu dữ liệu (data noise).

2. ĐÁNH GIÁ MÔ HÌNH B: CONTENT-BASED

Mô hình này không quan tâm user là ai, nó chỉ quan tâm "Sách này giống sách kia không?".

- **Cách đánh giá:** Lấy một cuốn sách bất kỳ, yêu cầu mô hình gợi ý 10 cuốn tương tự. Sau đó kiểm tra xem các cuốn gợi ý đó có cùng **Tác giả** với cuốn gốc không.

Các chỉ số đo lường:

1. Precision@K (Độ chính xác)

- **Kết quả:** 41.70%
- **Giải thích:** Trong 5 cuốn sách được gợi ý, có khoảng 2 cuốn là cùng tác giả với cuốn sách gốc.
- **Đánh giá:** Rất tốt. Điều này chứng tỏ thuật toán TF-IDF đã hoạt động hiệu quả trong việc nhóm các cuốn sách có nội dung/metadata tương đồng lại với nhau.

2. Recall@K (Độ bao phủ)

- **Kết quả:** 38.44%
- **Giải thích:** Hệ thống tìm được khoảng 38% tổng số sách của tác giả đó có trong kho dữ liệu.

3. F1-Score

- **Kết quả:** 40.01%
- **Giải thích:** Đây là điểm trung hòa giữa độ chính xác và độ bao phủ. Mức 40% là con số ấn tượng cho một thuật toán không cần dữ liệu lịch sử người dùng.

VI. DEMO & TRIỂN KHAI (DEPLOYMENT)

1. Giao diện Demo

- Sử dụng thư viện `ipywidgets` để tạo giao diện tương tác ngay trên Notebook.
- **Tính năng:**
 - Ô nhập User ID.
 - Nút "Tìm kiếm".
 - Hiển thị kết quả: Danh sách 5 cuốn sách gợi ý kèm hình ảnh bìa sách (lấy từ URL).
 - Hiển thị thông báo trạng thái: Hệ thống đang dùng thuật toán nào (ALS, Content-Based hay Popular).

2. Kịch bản kiểm thử (Test Cases)

- **Nhập ID 276729 (Core User):** Hệ thống dùng ALS -> Gợi ý sách dựa trên hành vi cộng đồng.
 - **Nhập ID 8 (Lukewarm User):** Hệ thống dùng Content-Based -> Gợi ý sách giống cuốn vừa đọc.
 - **Nhập ID 999999 (User mới):** Hệ thống dùng Popular -> Gợi ý sách "Harry Potter", "The Lovely Bones"...
-

VII. KẾT LUẬN & HƯỚNG PHÁT TRIỂN

- **Kết luận:** Hệ thống Hybrid hoạt động ổn định, giải quyết được vấn đề cold start mà một mô hình đơn lẻ không làm được.
- **Hạn chế:** Chỉ số AUC của mô hình ALS chưa cao do dữ liệu quá thưa và nhiễu.
- **Nguyên nhân:**
 - **Dữ liệu thưa (Sparsity):** Với độ thưa 99.99%, việc tìm ra mẫu hình chung là cực kỳ khó khăn.
 - **Giới hạn tài nguyên:** Do chạy trên môi trường Colab giới hạn RAM, nhóm buộc phải lọc dữ liệu rất mạnh tay (chỉ giữ User/Book > 50 tương tác), dẫn đến mất mát thông tin quý giá (Underfitting).
 - **Xử lý Rating:** Hiện tại đang gộp chung rating thấp và cao thành "có tương tác", làm giảm khả năng phân biệt sở thích chi tiết.
- **Hướng phát triển:**
 - Thu thập thêm dữ liệu hành vi (thời gian đọc, click).
 - Tinh chỉnh tham số (Hyperparameter tuning) kỹ hơn cho ALS.
 - Sử dụng các mô hình Deep Learning (Neural Collaborative Filtering) để cải thiện độ chính xác.